SLM 기반 NPC는 손님의 거짓 주장에 속지 않을 수 있는가

ABCD 실험 종합 보고서 (v4 ~ v6) · 2026-10-21 · 저장소 `conference-paper` (최종 커밋 123e08a)

> **한 줄 결론** — 판단은 SLM이 아니라 **결정표(코드)**가 해야 한다. SLM에게는 "손님이 무슨 주장을 했는지 알아듣기"만 맡기는 것이 가장 정확했다.
> 결정표 정확도 **83.3%**는 다른 방식보다 높았다: SLM 직접 판단 45.6%, SLM+검색 40.6%, SLM+도구 호출 63.4% (v4). 처음 보는 데이터(검증 세트)에서도 결정표 74.8%로 가장 높았다(SLM 직접 판단 41.8%, 도구 호출 64.6%).
> 결정표는 진짜 손님을 거부한 적이 한 번도 없었다(0%).

1. 무엇을 알고 싶었나

게임 속 상점 NPC에게 손님이 "8일 전에 할인 코드를 받았어요", "물건을 이미 반품했어요" 같은 말을 한다. 이 말은 사실일 수도, 거짓일 수도 있다. NPC는 가게 장부를 보고 다음 중 하나를 골라야 한다.

- **믿기**: 장부에 그 기록이 있고 날짜도 맞다
- **증거 요구**: 장부에 기록이 없다
- **반박**: 기록은 있지만 날짜가 다르다

연구 질문: 이 판단을 작은 언어 모델(SLM)에게 맡겨야 하는가, 아니면 코드로 된 규칙(결정표)에 맡겨야 하는가?

2. 실험 설계

2.1 데이터

- **손님 문장**: 실제 고객센터 대화 데이터셋 ABCD(Action-Based Conversations Dataset, NAACL 2021)에서 가져왔다. 손님이 첫 세 마디 안에 거래 관련 주장을 한 대화를 규칙으로 골랐다.
  - 주장 종류는 5가지: 할인 약속, 반품 완료, 이중 청구, 주문 미수령, 구매(소유)
- **장부**: ABCD에는 대화만 있고 거래 기록이 없어서, 장부는 규칙으로 **합성**했다.
- **같은 문장으로 세 판을 만들었다.** 손님 문장은 그대로 두고 장부만 바꾼다. 그래서 장부의 영향만 비교할 수 있다.

판	장부 상태	정답
v (기록 있음)	주장과 같은 종류·같은 날짜의 기록이 있다	믿기
n (기록 없음)	그 종류의 기록이 없다	증거 요구
d (날짜 불일치)	기록은 있지만 날짜가 다르다	반박

데이터 세트	출처	원천(대화) 수	시나리오 수	용도
v4 세트	ABCD train 분할	84	252	본 실험
검증 세트	ABCD dev+test 분할 (v4와 겹침 0)	59	177	처음 보는 데이터에서 다시 확인

2.2 공정성 장치

- **정답 분리**: 정답표는 실행 코드와 다른 파일에 두었다. 실행 중에는 읽지 않으며, 테스트로 확인했다.

- **사전등록과 봉인**: 실험마다 가설·지표·채택 규칙을 먼저 문서로 쓰고, 해시로 봉인한 뒤 실행했다.
- **반복**: 모든 조건을 seed 3개(11, 29, 47)로 돌렸다.
- **검정**: 대화 원천 단위로 짝지은 sign-flip 검정(20,000회)을 했다. 여러 비교에는 Holm 보정을 적용했고, 신뢰구간은 bootstrap 95%로 구했다.
- **모델**: Ornith 1.5 9B(4비트 양자화)를 노트북의 llama-server에서 돌렸다. 모든 조건이 같은 모델을 쓴다.

2.3 비교한 방식 (판단을 어디에 맡기느냐)

조건	장부 전달 방식	판단 주체
F-M1P0: SLM 직접 판단	그 손님의 장부 전체를 프롬프트에 넣음	SLM
S-M1P0: SLM + 검색 (RAG)	벡터 검색으로 고른 장부 5줄	SLM
T-M1P0: SLM + 도구 호출	SLM이 `lookup(주장 종류)`을 호출하면 해당 기록을 돌려줌 (τ-bench가 평가하는 방식)	SLM
F-M1P1: 결정표	**SLM은 주장 종류만 분류하고, 엔진이 장부를 조회함**	**결정표(코드)**

결정표 조건에서 SLM은 두 가지만 한다. 손님 문장이 어떤 주장인지 분류하는 일(이하 "귀", NLU)과 결정에 맞는 대사를 쓰는 일이다.

3. 결과

3.1 본 실험 v4: 누가 판단해야 하나 (각 조건 756회)

조건	v 정답	n 정답	d 정답	전체 정확도
SLM 직접 판단	52.8%	56.3%	27.8%	45.6%
SLM + 검색	32.9%	76.6%	12.3%	40.6%
SLM + 도구 호출 (v6)	63.9%	98.0%	28.2%	63.4%
결정표	**91.3%**	**83.7%**	**75.0%**	**83.3%**

- 결정표가 SLM 직접 판단보다 **+37.7%p** 높았다. v4의 사전등록 채택 규칙을 충족했다.
- 결정표의 오류는 **모두 SLM이 주장을 잘못 알아들은 경우**였다. 장부 조회와 결정 규칙은 한 번도 틀리지 않았다.
- 약점도 있었다. 기록 없는 주장을 믿은 비율이 결정표 16.3%로, SLM 직접 판단(2.0%)보다 높았다. 귀가 주장을 놓치면 결정표가 그 말을 "주장 없음"으로 보고 넘어가기 때문이다.

도구 호출 줄의 v·n 정답률은 v6 결정 분포에서 계산했다(v 161/252, n 247/252).

3.2 수용 / 보류 / 거부로 다시 본 결과 (사후 분석)

"증거를 보여 주세요"는 거절이 아니라 확인 질문이다. 그래서 결정을 세 갈래로 묶어 다시 셌다. 기준은 계산 전에 문서로 고정했다(커밋 e2791a9). 다만 결과를 본 뒤 만든 기준이므로 **사후 탐색 분석**이다.

조건 (v4)	속음 (n·d에서 믿음)	진짜 손님 거부 (v에서 반박·거절)	확인 질문 (v에서 보류)	진짜 손님 수용
SLM 직접 판단	22.0%	27.4%	19.8%	52.8%
SLM + 검색	12.9%	13.5%	53.6%	32.9%
SLM + 도구 호출	24.4%	11.9%	24.2%	63.9%
결정표	**16.3%**	**0%**	**8.7%**	**91.3%**

결정표는 **진짜 손님을 반박하거나 거절한 적이 없다.** 결정표의 오류는 "속음"이나 "확인 질문"뿐이었다.

3.3 v6: 표준 도구 호출 방식과의 비교 (사전등록, 1,287회)

데이터	결정표	도구 호출	차이 [95% CI]	Holm p
v4 세트	83.3%	63.4%	**+20.0%p** [14.3, 25.7]	0.0001
검증 세트	74.8%	64.6%	**+10.2%p** [1.7, 18.5]	0.022

- **SLM은 찾기는 잘했다.** 도구를 호출한 비율이 96~100%, 맞는 종류를 고른 비율이 94%, 형식 실패는 0회였다.
- **판단은 못했다.**
  - 날짜가 어긋난 주장을 반박한 비율이 결정표보다 36~47%p 낮았다(Holm p = 0.0002).
  - 날짜가 다른데도 기록을 보고 믿은 경우가 39~48%였다.
  - 진짜 손님을 반박한 경우가 12~19%였다.

- 도구가 있으면 SLM 직접 판단보다는 낫다(+17.7%p, v4). 그래도 결정표에는 못 미쳤다.

3.4 남은 오류를 줄이려는 시도

결정표의 남은 약점은 귀가 주장을 놓치는 것이다. 예를 들면 "제 할인 코드가 안 돼요"처럼 **주장이 전제로 깔린 문장**이다. 이를 보완하려고 두 가지를 시험했다.

시도	방법	결과
fail-closed (v4 후속)	귀가 "주장 없음"이라 했는데 거래 단어(코드, 주문, 환불 등)가 있으면 무조건 증거 요구	속음 16.3% → 0%. 대신 진짜 손님에게 확인 질문을 하는 비율이 같은 만큼 증가. 233/756회에서 사용자 판단으로 중단했고, 끝난 실행은 오프라인 예측과 100% 일치
재확인 RV (v5)	같은 SLM에게 "할인 코드를 받았다고 주장하나요? 예/아니오"로 다시 물음	113건 중 110건이 "아니오". 정확도 +0.8%p(p = 0.51)로 **채택 안 됨**

검증 세트의 3분류 결과 (사후 분석)

조건 (검증 세트)	속음	진짜 손님 거부	확인 질문	진짜 손님 수용
결정표	24.9%	0%	13.0%	87.0%
결정표 + fail-closed	3.4%	0%	33.9%	66.1%
결정표 + 재확인	3.4%	0%	33.3%	66.7%

fail-closed를 더하면 **"속기"가 "한 번 더 묻기"로 바뀐다.** 진짜 손님을 거부하는 일은 여전히 없다. 그 대가로 진짜 손님의 약 3분의 1이 확인 질문을 한 번 더 받는다.

3.5 처음 보는 데이터(검증 세트)에서 다시 확인 (사전등록, 각 조건 531회)

조건 (검증 세트, 59원천)	v 정답	n 정답	d 정답	전체 정확도	속음	진짜 손님 거부
SLM 직접 판단	42.4%	62.7%	20.3%	41.8%	18.4%	24.9%
SLM + 도구 호출	68.9%	98.3%	26.6%	64.6%	27.7%	18.6%
결정표	**87.0%**	**74.6%**	**62.7%**	**74.8%**	**24.9%**	**0%**

- 결정표가 SLM 직접 판단보다 **+33.0%p** 높았다(95% CI [24.1, 41.6], p < .0001). v4의 +37.7%p와 거의 같은 차이가 처음 보는 데이터에서도 재현되었다.
- 부 지표(Holm 보정)도 모두 유의했다(Holm p < .001).
  - 도구 호출이 SLM 직접 판단보다 +22.8%p 높았다.
  - 날짜 불일치 반박률은 결정표가 +42.4%p 높았다.
  - 진짜 손님 거부율은 SLM 직접 판단이 +24.9%p 높았다.
- 순위는 두 세트 모두 같다: **결정표 > 도구 호출 > SLM 직접 판단**.
- 처음 보는 문장에서는 귀가 주장을 더 자주 놓쳐서 결정표의 정확도가 83.3%에서 74.8%로 떨어졌다. 그래도 진짜 손님 거부는 두 세트 모두 0%였다.

4. 결론

> 1. **판단은 SLM이 아니라 결정표가 해야 한다.** 장부를 통째로 주든(45.6%), 검색해서 주든(40.6%), 도구로 찾게 하든(63.4%), SLM이 판단하면 결정표(83.3%)보다 정확도가 낮았다. 처음 보는 데이터에서도 순위는 같았다(결정표 74.8% > 도구 호출 64.6% > SLM 직접 판단 41.8%).
> 2. **SLM은 장부를 "찾는" 일은 잘하지만, 찾은 기록으로 "판단하는" 일, 특히 날짜 대조는 잘하지 못한다.**
> 3. **결정표의 남은 오류는 모두 "알아듣기" 단계에서 생긴다.** 특히 전제로 깔린 주장에서 생긴다. 같은 SLM에게 다시 물어도 회복되지 않았다.
> 4. **fail-closed를 더하면 속는 것을 확인 질문으로 바꿀 수 있다.** 진짜 손님을 거부하지 않는 성질은 그대로 유지된다.

논문용 요약. SLM 기반 NPC가 손님 주장을 장부와 대조하는 과제에서 판단을 SLM에 맡기는 방식(직접 판단, RAG, tool-calling)은 모두 결정표보다 정확도가 낮았다. SLM은 장부를 정확히 검색했지만, 검색 결과로 판단하는 단계, 특히 날짜 대조에서 실패했다. 판단을 결정표로 옮기자 정당한 손님을 거부하는 오류가 사라졌다. 남은 오류는 SLM이 주장을 알아듣는 단계에 집중되었다.

5. 한계

- **합성 장부.** 장부가 실제보다 깨끗하다. 또 "믿기"는 종류와 날짜가 모두 맞을 때만 나와서 구조적으로 안전하다. 실제 가게 장부에서는 이 안전성이 약해질 수 있다.
- **모델 하나, 작은 표본.** 9B 모델 하나로만 실험했고, 원천은 84개와 59개다.
- **도구 호출을 흉내 냈다.** 실제 function calling API가 아니라 JSON 출력으로 흉내 냈다. 또 τ-bench 자체를 재현한 것이 아니다.
- **검증 세트의 비교 범위.** 검증 세트에서는 SLM + 검색(RAG) 조건을 돌리지 않았다.
- **사후 분석.** 3분류 결과는 사후 탐색 분석이다.
- **라벨 모호성.** 귀가 놓친 문장 중 일부("할인 코드 언제 써요?")는 주장인지 사람마다 판단이 갈릴 수 있다.
- **대사 품질은 평가하지 않았다.**

6. 후속 연구

- 확인 질문 이후의 대화. 손님이 코드나 주문번호를 대면 엔진이 다시 대조한다.
- 귀(NLU) 개선: 다른 SLM, 전제된 주장의 예시 추가. 결정이 귀의 출력만으로 정해지므로 저비용으로 비교할 수 있다.
- 명시적 주장과 전제된 주장을 나눈 라벨링과 결과 보고
- 실제 거래 데이터와 실제 function calling으로 재검증

부록. 실험 기록

실험	실행 수	사전등록	결과 위치	커밋
v4 본 실험	2,268	docs/ABCD_v4_사전등록.md	results/abcd4/	55fa34d, 741c7a0
fail-closed	233 (중단)	docs/ABCD_v4_failclosed_사전등록.md	results/abcd4fc/	3fabff7
v5 재확인	1,407	docs/ABCD_v5_reverify_사전등록.md	results/abcd5/	362e0de
3분류 사후 분석	(재집계)	docs/ABCD_3way_사후분석.md	results/abcd_3way/	e2791a9, 1a006c7
검증 세트 SLM 직접 판단	531	docs/ABCD_v5_P0추가_사전등록.md	results/abcd5p0/	(이번 커밋)
v6 도구 호출	1,287	docs/ABCD_v6_toolcall_사전등록.md	results/abcd6/	123e08a

v4, v5, v6은 별도의 게이트 리뷰에서 승인을 받았다. 리뷰어가 독립적으로 다시 계산한 수치도 보고서와 일치했다.